Nocera Alessio

ECONOMÉTRIE

Modélisation et Prévision de la Volatilité des Rendements du Pétrole Brent : Une approche comparative entre modèles GARCH et EGARCH

I. Introduction

Le marché pétrolier, et plus particulièrement celui du brut de référence Brent, joue un rôle prépondérant dans l'économie mondiale et dicte une grande partie des dynamiques macroéconomiques et financières internationales. Au cours de la dernière décennie, ce marché a été le théâtre d'une instabilité chronique et de fluctuations de prix d'une rare violence. Ces mouvements erratiques s'expliquent par une forte sensibilité aux événements exogènes : la crise sanitaire de la COVID-19 a provoqué un effondrement brutal de la demande, tandis que la succession de chocs géopolitiques majeurs (la guerre en Ukraine) a généré de sévères perturbations sur l'offre.
En finance, la volatilité est la principale mesure du risque. Une modélisation précise de cette dernière est donc indispensable pour la gestion des risques, la mise en place de stratégies de couverture (hedging), ainsi que pour l'évaluation des actifs financiers. Or, l'analyse des séries temporelles financières se heurte à une limite majeure des modèles de régression linéaire classiques (par la méthode des Moindres Carrés Ordinaires) : ces modèles reposent sur l'hypothèse d'une variance constante du terme d'erreur (homoscédasticité). Dans la réalité, les rendements financiers, comme ceux du Brent, présentent une variance qui évolue dans le temps et se caractérisent par des « grappes de volatilité » (hétéroscédasticité conditionnelle), où des périodes de fortes turbulences succèdent à des périodes de calme. Modéliser cette dynamique nécessite donc d'abandonner le cadre statique traditionnel au profit d'outils économétriques avancés, capables de capter l'évolution de la variance.
L'objectif est d'analyser la dynamique de la volatilité des rendements du pétrole Brent et d'en proposer des prévisions robustes.
Dans un premier temps, nous définirons notre problématique, axée sur la nécessité de capter l'asymétrie des chocs sur le marché pétrolier.
Ensuite, nous présenterons les données utilisées ainsi que les transformations opérées pour obtenir des séries stationnaires. Une analyse statistique descriptive permettra de mettre en évidence les faits stylisés de notre série.
La section suivante sera consacrée à la présentation de notre démarche analytique : nous détaillerons les tests de stationnarité (ADF et KPSS) et justifierons économétriquement l'utilisation des modèles de la famille GARCH.
Nous exposerons ensuite les résultats obtenus lors de nos estimations, avant de comparer les performances prédictives de nos modèles grâce au test de précision de Diebold-Mariano.
Enfin, nous synthétisons nos recherches, mettons en lumière le modèle le plus performant pour réaliser nos prévisions à court terme, et évoquons les limites de notre approche.

II. Présentation de la problématique

L'analyse et la prévision des séries temporelles financières posent des défis majeurs qui rendent les approches économétriques traditionnelles inopérantes. Dans le cadre classique d'une régression linéaire estimée par la méthode des MCO, la validité des estimateurs repose sur plusieurs hypothèses strictes. Parmi elles, l'hypothèse d'homoscédasticité du terme d'erreur stipule que la variance doit rester constante dans le temps. Or, les séries de prix d'actifs, telles que le baril de pétrole Brent, sont non seulement non-stationnaires (elles s'apparentent à une marche aléatoire), ce qui impose de les transformer en log-rendements pour les étudier, mais elles porte aussi un problème sur l'hypothèse d'homoscédasticité. Empiriquement, les rendements financiers se caractérisent par une hétéroscédasticité conditionnelle. Ils présentent des épisodes de « grappes de volatilité » (ou volatility clustering) : de fortes variations de prix ont tendance à être suivies par de fortes variations, et inversement pour les périodes de calme.

Pour pallier cette limite et modéliser le fait que la variance s'ajuste dynamiquement en fonction de l'information passée, la littérature s'appuie sur les modèles de la famille ARCH (testés formellement par le test du multiplicateur de Lagrange d'Engle) et GARCH. Cependant, bien que le modèle standard GARCH(1,1) permette de capter la persistance de cette volatilité, il souffre d'une limite structurelle importante : il impose une contrainte de symétrie parfaite. Mathématiquement, ce modèle postule qu'un choc inattendu positif ou négatif de même ampleur absolue engendrera exactement la même augmentation de la variance conditionnelle.

Pourtant, le comportement des agents économiques sur les marchés pétroliers face au risque est rarement symétrique. Il est fréquent d'observer un « effet de levier », c'est-à-dire une situation où les chocs positifs (par exemple, une augmentation soudaine des prix) génèrent davantage d'incertitude et accroissent la volatilité de manière beaucoup plus marquée que les chocs négatifs. Pour contourner cette restriction, Nelson (1991) a introduit le modèle asymétrique EGARCH (Exponential GARCH). En modélisant le logarithme de la variance conditionnelle, l'EGARCH permet non seulement de garantir la positivité de la variance sans imposer de contraintes sur les paramètres, mais il intègre surtout un paramètre d'asymétrie destiné à capturer et quantifier cet effet de levier.

À cette asymétrie s'ajoute un autre fait intéressant : la distribution des rendements du pétrole présente des « queues épaisses » (leptokurtique), ce qui signifie que la probabilité d'observer des valeurs extrêmes est bien supérieure à ce que prédirait une loi normale classique. Une modélisation pertinente doit donc également s'affranchir de l'hypothèse de normalité des erreurs pour adopter des distributions plus adaptées, comme la loi de Student.

C'est avec ces enjeux économétriques que notre problématique de recherche est introduite : Dans quelle mesure la prise en compte de l'asymétrie des chocs via un modèle EGARCH permet-elle de mieux capturer la dynamique complexe de la volatilité des rendements du pétrole Brent, et d'en améliorer significativement les performances prédictives par rapport à un modèle symétrique classique GARCH ?

Autrement dit, nous chercherons à vérifier si l'effet de levier est une composante indispensable pour modéliser le marché du Brent aujourd'hui, et si ce gain théorique d'ajustement se traduit par un réel avantage empirique lors de prévision, ce que nous évaluerons formellement à l'aide des critères d'information (AIC/BIC) et du test de précision prédictive de Diebold-Mariano.

III. Présentation des données utilisées

Les données utilisées dans le cadre de cette étude proviennent de la base FRED (série « DCOILBRENTEU ») et regroupent les observations journalières du prix du pétrole Brent sur une période de 10 ans, s'étendant de mars 2016 à mars 2026 (Figure 1).

- FRED DCOILBRENTEU, fréquence journalière
- 2 mars 2016 → 2 mars 2026
- 2609 observations brutes, 70 NA supprimés, 2538 rendements

Le passage des prix bruts aux rendements logarithmiques rt est une transformation essentielle en économétrie. D'une part, elle atténue l'hétéroscédasticité des séries financières et favorise la symétrie de leur distribution (Campbell, Lo & MacKinlay, 1997). D'autre part, ces log-rendements offrent des avantages analytiques supérieurs aux rendements arithmétiques, notamment l'additivité temporelle et une évaluation parfaitement symétrique des gains et des pertes (Hudson & Gregoriou, 2015).

$$r_t = \log(P_t) - \log(P_{t-1})$$

Dans le cadre de la modélisation de la volatilité stochastique et conditionnelle (de type GARCH), l'utilisation des rendements composés en continu est privilégiée. Elle s'inscrit en parfaite cohérence avec le cadre en temps continu de la théorie moderne de l'évaluation des actifs (Black & Scholes, 1973). Par ailleurs, bien que la distribution empirique des log-rendements présente souvent des queues épaisses (leptokurticité), elle constitue une bien meilleure approximation de la normalité que la distribution des prix ou des rendements simples (Cont, 2001).

Figure 1: Prix quotidiens du Brent

Source : FRED - DCOILBRENTEU

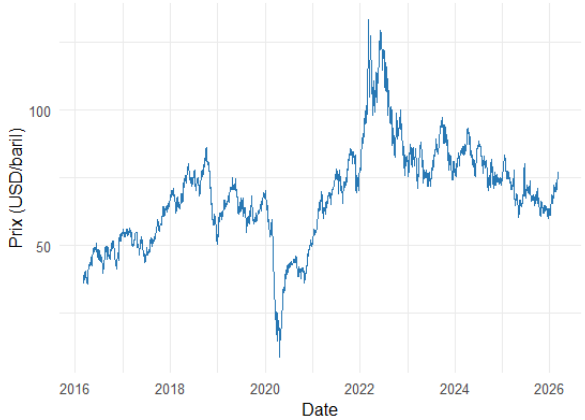

Figure 2: Log-rendements journaliers du Brent

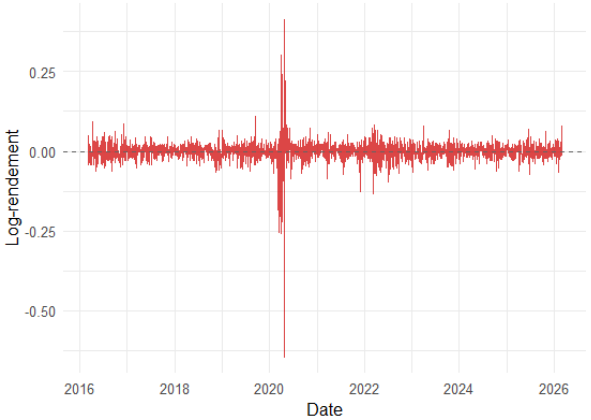

Enfin il est impératif de s'assurer des propriétés stochastiques de la série temporelle étudiée, en l'occurrence les rendements rt. En effet, la validité asymptotique de ces modèles repose sur l'hypothèse stricte que l'équation de la moyenne de la série est au minimum faiblement stationnaire (au second ordre). Travailler sur une série non stationnaire exposerait l'analyse au risque de régressions fallacieuses (Granger & Newbold, 1974) et rendrait l'inférence statistique invalide d'où l'utilité des log rendement. Les tests seront montrés par la suite.

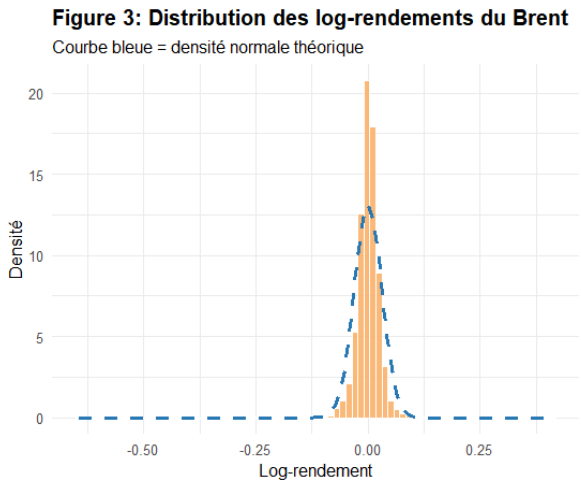

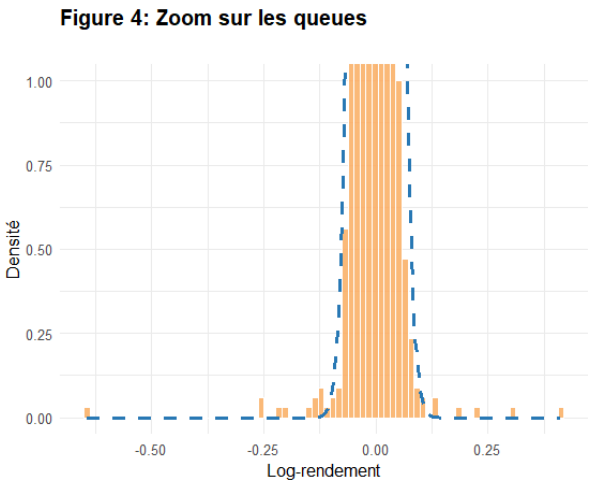

L'analyse de la distribution des log-rendements (Figure 3) et des statistiques descriptives (Tableau 1) révèle trois caractéristiques fondamentales. Premièrement, La série se caractérise par une leptokurticité extrême (kurtosis = 104,65), confirmant la présence de « queues épaisses » et une récurrence de variations brutales des prix bien au-delà des prédictions d'une distribution normale Cette propriété, visible sur le zoom des queues (Figure 4), justifie l'utilisation d'une distribution de Student-t dans l'estimation des modèles GARCH.
Deuxièmement, le skewness négatif (−3) indique une asymétrie prononcée vers les rendements négatifs, reflétant le caractère des krachs pétroliers notamment le choc COVID d'avril 2020 par rapport aux hausses de prix.
Troisièmement, l'écart-type journalier de 3.05% souligne la volatilité intrinsèque du marché pétrolier, supérieure à celle des marchés actions développés (autour de 1,2%). Ces trois caractéristiques motivent conjointement le recours aux modèles GARCH à distribution asymétrique.

Tableau 1 : Statistiques descriptives

Indicateur	Valeur
Moyenne	+0.000297
Variance	0.000933
Écart-type	0.030543
Skewness	-3.0066
Kurtosis	104.6507

IV. Présentation de l'analyse réalisée

Afin d'évaluer formellement cette propriété de stationnarité, la littérature économétrique préconise le recours aux tests de racine unitaire. Le test le plus usuel dans la modélisation

financière est le test *Augmented Dickey-Fuller* ou ADF (Dickey & Fuller, 1979, 1981). Dans le cadre de ce test, l'hypothèse nulle (H0) postule la présence d'une racine unitaire, traduisant ainsi la non-stationnarité de la série, contre l'hypothèse alternative (H1) de stationnarité. Sur le plan décisionnel, si la *p-value* empirique associée à la statistique de test est strictement inférieure au seuil de signification usuel ($\alpha = 0,05$), l'hypothèse nulle est rejetée, ce qui corrobore la stationnarité de la série temporelle.

La stationnarité est confirmée par une analyse confirmatoire (ADF/KPSS) : le rejet de la racine unité par l'ADF ($p < 0.01$) et le non-rejet de l'hypothèse nulle par le KPSS ($p = 0.10$) valident l'utilisation de la série en log-rendements. Contrairement au test ADF, le test KPSS renverse le paradigme : l'hypothèse nulle (H0) stipule que la série est stationnaire, tandis que l'hypothèse alternative (H1) indique la présence d'une racine unitaire. Ainsi, l'observation d'une *p-value* supérieure au seuil de tolérance de 5 % conduit à ne pas rejeter H0, validant de fait la stationnarité.

Conformément aux recommandations méthodologiques standard pour l'analyse des séries temporelles (Maddala & Kim, 1998), l'application conjointe de ces deux procédures permet d'effectuer une analyse confirmatoire (*confirmatory analysis*). La stationnarité de la série des rendements est considérée comme robuste et définitivement établie si, et seulement si, les deux tests convergent vers la même conclusion logique : le rejet de l'hypothèse nulle par le test ADF, conjugué au non-rejet de l'hypothèse nulle par le test KPSS.

Le test de Dickey-Fuller Augmenté (ADF) appliqué aux log-prix génère une statistique de -3,3054 (p-value = 0,0697). Supérieure au seuil de 5 %, cette valeur ne permet pas de rejeter l'hypothèse de racine unitaire, confirmant la non-stationnarité de la série. Conformément à la théorie de la marche aléatoire des actifs financiers (Samuelson, 1965 ; Fama, 1965, 1970), cette série s'apparente à un processus intégré d'ordre un, noté I(1), et exige une différenciation première pour atteindre la stationnarité (Nelson & Plosser, 1982 ; Campbell, Lo & MacKinlay, 1997).

Afin d'obtenir une série stationnaire, condition nécessaire pour la modélisation économétrique, nous avons appliqué une différenciation première, générant ainsi la série des log-rendements. L'application du test ADF sur cette nouvelle série donne une statistique de -11,845 avec une *p-value* empirique hautement significative (inférieure à 0,01). Ce résultat nous permet de rejeter catégoriquement l'hypothèse nulle de non-stationnarité.

Pour confirmer cette conclusion, nous avons procédé à une analyse via le test KPSS sur cette même série de log-rendements. La statistique calculée s'élève à 0,0559, correspondant à une *p-value* de 0,10. Étant supérieure au seuil critique de 5 %, elle nous conduit à ne pas rejeter l'hypothèse nulle de stationnarité propre au test KPSS.

Les résultats des deux procédures convergent vers le même résultat : le test ADF rejette la présence d'une racine unitaire, tandis que le test KPSS valide la stationnarité. L'utilisation de ces deux tests nous permet de conclure que la série des log-rendements étudiée est stationnaire. Cette étape validée assure la pertinence et la robustesse asymptotique de l'estimation future de notre modèle GARCH.

Avant de procéder à l'estimation d'un modèle de la famille GARCH, il est indispensable de démontrer statistiquement que la variance de la série n'est pas constante dans le temps

(homoscédasticité), mais qu'elle dépend des chocs passés (hétéroscédasticité conditionnelle). Pour détecter cette dynamique, qui se traduit visuellement par des grappes de volatilité (*volatility clustering*), la littérature économétrique préconise le recours à deux tests fondamentaux : le test de Ljung-Box appliqué aux carrés des rendements et le test ARCH-LM.

Appliqué aux rendements au carré pour détecter la persistance de la volatilité, le test de Ljung-Box (retard k=10) génère une statistique Q de 555,54 (p-value < 2,2.10^-16), rejetant formellement l'absence d'autocorrélation. Conjointement, le test ARCH-LM (p < 0,001) permet de rejeter l'hypothèse nulle d'homoscédasticité conditionnelle. Ces résultats prouvent l'existence d'une forte dépendance non linéaire et confirment la présence de « grappes de volatilité » (Mandelbrot, 1963), justifiant pleinement le recours à une modélisation GARCH

Le test ARCH-LM mené sur notre série avec 10 retards renvoie une statistique du Chi2 de 450,41. La *p-value* empirique s'établit à 1,71.10^(-90), une valeur très largement inférieure au seuil de tolérance usuel de 5 % (et même de 1 %). Par conséquent, nous rejetons l'hypothèse nulle. Ce résultat atteste de la présence d'effets ARCH hautement significatifs dans la série des rendements du Brent. Les résultats des deux procédures sont parfaitement convergents. La présence d'une variance conditionnelle variant dans le temps est confirmée de manière robuste. Cette étape valide formellement la nécessité d'abandonner les modèles linéaires classiques à variance constante et justifie la spécification et l'estimation d'un modèle de type GARCH (Bollerslev, 1986) pour capter la dynamique de la volatilité du pétrole.

Figure 5 : Analyse de l'autocorrélation et des effets ARCH

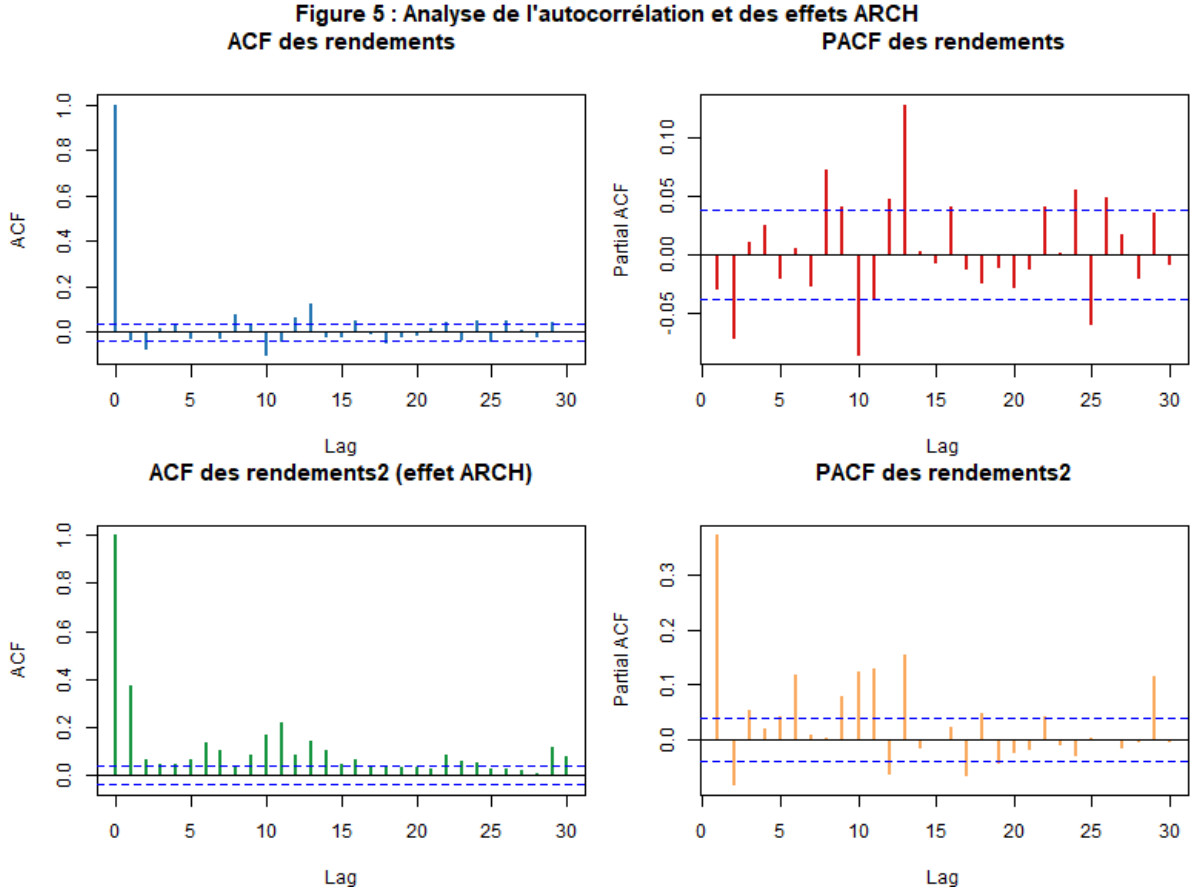

Les fonctions d'autocorrélation (ACF) et d'autocorrélation partielle (PACF) des log-rendements confirment l'absence de structure linéaire dans la moyenne : les coefficients restent dans les bandes de confiance à 95% pour la quasi-totalité des lags, validant le choix d'une spécification ARMA(0,0). En revanche, l'analyse des rendements au carré révèle une auto-corrélation forte.
Le coefficient d'autocorrélation au lag 1 atteint 0.40 et reste significatif jusqu'au lag 15, traduisant un clustering de volatilité prononcé, les périodes de forte turbulence tendent à se regrouper dans le temps. La PACF des rendements au carré, dont le pic dominant au lag 1 est suivi d'une décroissance rapide, suggère qu'un modèle GARCH(1,1) est une spécification parcimonieuse et appropriée pour capturer cette dynamique. Ces résultats, corroborés par le test ARCH-LM (Chi^2=450,41, p<0.001), constituent une motivation empirique solide pour l'estimation de modèles GARCH. La forte leptokurticité (104.65) et le rejet de la normalité par Jarque-Bera imposent l'usage d'une distribution de Student-t.

Spécification du modèle GARCH(1,1)

Le modèle GARCH(1,1) (Bollerslev, 1986) modélise la variance conditionnelle selon :

$$r_t = \mu + \varepsilon_t, \quad \varepsilon_t = \sigma_t z_t, \quad z_t \sim \text{Student}(\nu)$$

$$\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2$$

où α mesure la réactivité aux chocs passés et β la persistance de la volatilité. La somme α+β représente la persistance totale : proche de 1, elle indique une mémoire longue des chocs de volatilité.

Spécification du modèle EGARCH(1,1)

Le modèle EGARCH(1,1) (Nelson, 1991) modélise le logarithme de la variance conditionnelle :

$$\log(\sigma_t^2) = \omega + \alpha \left(|z_{t-1}| - \mathbb{E}[|z|]\right) + \gamma z_{t-1} + \beta \log(\sigma_{t-1}^2)$$

Le paramètre γ capture l'asymétrie de la réponse de la volatilité aux chocs positifs et négatifs.Contrairement au GARCH standard, l'EGARCH garantit la positivité de σ2t sans contrainte sur les paramètres, et modélise explicitement l'effet de levier via γ≠0

V. Présentation des résultats obtenus

Résultats de l'estimation GARCH(1,1)

Tableau 2: GARCH(1,1) — Résultats d'estimation (Student-t, ARMA(0,0))

Paramètre	Estimé	Écart-type	t-stat	p-value
μ (mu)	0.001153	0.000372	3.1032	0.0019 **
ω (omega)	0.000024	5e-06	4.7414	0.0000 ***
α (alpha1)	0.097857	0.014254	6.865	0.0000 ***
β (beta1)	0.858444	0.017156	50.0365	0.0000 ***
shape	5.827799	0.643765	9.0527	0.0000 ***
α + β (persistance)	*0.956300*	—	—	—
Demi-vie (jours)	*15.500000*	—	—	—

Résultats de l'estimation EGARCH(1,1)

Tableau 3: EGARCH(1,1) : résultats d'estimation (Student-t, ARMA(0,0))

Paramètre	Estimé	Écart-type	t-stat	p-value
μ (mu)	0.000972	0.000371	2.6232	0.0087 **
ω (omega)	-0.233118	0.019376	-12.0313	0.0000 ***
α (alpha1)	-0.066298	0.014487	-4.5764	0.0000 ***
γ (gamma1)	0.170694	0.023239	7.3451	0.0000 ***
β (beta1)	0.969881	0.002487	389.9598	0.0000 ***
shape	5.8288	0.6423	9.0750	0.0000 ***
β (persistance)	*0.9699*	—	—	—
Demi-vie (jours)	*22.7*	—	—	—

Comme l'indiquent les Tableaux 2 et 3, la persistance est très élevée dans les deux modèles (0.956 pour le GARCH, 0.969 pour l'EGARCH), indiquant que les chocs de volatilité se dissipent lentement, avec une demi-vie de 15.5 jours pour le GARCH et 22.7 jours pour l'EGARCH. Le paramètre $\gamma = +0.171$ est positif et hautement significatif ($t = 7.35$, $p < 0.001$). Contrairement à l'effet de levier classique observé sur les marchés actions ($\gamma < 0$, Black, 1976), où les baisses de prix amplifient davantage la volatilité, le Brent présente une asymétrie haussière : les hausses brutales des prix, associées aux tensions géopolitiques ou aux restrictions d'offre de l'OPEP, génèrent une incertitude plus forte que les baisses de même amplitude. Ce résultat est cohérent avec Kang, Kang & Yoon (2009) qui documentent cette asymétrie positive sur les marchés pétroliers.

Nous avons utilisé le test de Jarque-Bera sur les résidus pour vérifier s'ils sont gaussiens. Le test de Jarque-Bera (Jarque & Bera, 1980), appliqué aux résidus standardisés des deux modèles, rejette massivement l'hypothèse de normalité (GARCH : $JB = 982.4$, $p < 2.2\times10^{-16}$; EGARCH : $JB = 1112.1$, $p < 2.2\times10^{-16}$).
Ce résultat, attendu sur données financières journalières (Bollerslev, 1987), ne remet pas en cause la qualité des modèles : la kurtosis des résidus standardisés est ramenée de 104.65 dans les données brutes à 5.87 pour le GARCH et 6.05 pour l'EGARCH, témoignant d'une réduction substantielle de l'excès de kurtosis. La non-normalité résiduelle persistante reflète la présence d'outliers extrêmes (COVID) dont aucun modèle GARCH paramétrique ne peut pleinement rendre compte. Les tests de Ljung-Box sur les résidus standardisés ($p = 0.45$ et $p = 0.47$) et sur leurs carrés ($p = 0.21$ et $p = 0.07$) confirment en revanche l'absence d'autocorrélation résiduelle, validant la spécification ARMA(0,0) et l'adéquation globale des deux modèles.

La sélection du modèle optimal repose sur une approche multicritère combinant les critères d'information, la comparaison des erreurs quadratiques moyennes (Tableau 4) et le test formel de Diebold & Mariano (1995).

Tableau 4 — Comparaison GARCH(1,1) vs EGARCH(1,1)

Critère	GARCH(1,1)	EGARCH(1,1)	Verdict
AIC	-4.8657	-4.8702	**EGARCH ✓**
BIC	-4.8542	-4.8564	**EGARCH ✓**
Log-Vraisemblance	6179.60	6186.31	**EGARCH ✓**
MSE	0.00008308	0.00008206	**EGARCH ✓**

Les critères d'Akaike (AIC) et de Schwarz (BIC) constituent une première base de comparaison. L'EGARCH(1,1) s'avère supérieur au GARCH(1,1) selon les critères d'information (AIC : -4.8702 ; BIC : -4.8564) et la log-vraisemblance. Les résultats obtenus sont sans ambiguïté : l'EGARCH(1,1) domine le GARCH(1,1) sur les deux critères (AIC : −4.8702 vs −4.8657 ; BIC : −4.8564 vs −4.8542) ainsi que sur la log-vraisemblance (6186.31 vs 6179.60). Il est important de noter que cette supériorité persiste malgré la pénalisation du paramètre supplémentaire γ propre à l'EGARCH — si l'ajout de ce paramètre n'améliore pas suffisamment l'ajustement.

La comparaison des erreurs quadratiques moyennes, calculées comme la moyenne de $(r^2_t - \sigma^2_t)^2$ où r^2_t constitue le proxy de la variance réalisée (Patton, 2011), confirme la légère supériorité de l'EGARCH. Le MSE de l'EGARCH (0.00008206) est inférieur à celui du GARCH (0.00008308), soit une réduction de 1.23% matérialisée par un ratio MSE de 0.9877. Cette réduction reflète la capacité de l'EGARCH à mieux ajuster les épisodes de forte volatilité grâce à la capture de l'asymétrie des chocs — les périodes de hausse brutale des prix générant une volatilité plus élevée que les baisses de même amplitude, comme le suggère le paramètre γ estimé.
Afin de déterminer si la différence de MSE observée est significative, nous appliquons le test de Diebold & Mariano (1995), pour comparer le pouvoir prédictif de deux modèles concurrents. Sous l'hypothèse nulle H0, les deux modèles ont le même pouvoir prédictif autrement dit, la différence des pertes quadratiques moyennes n'est pas significativement différente de zéro. Le test produit une statistique DM = 0.489 associée à une p-value de 0.625, conduisant au non-rejet de H0 au seuil de 5%. Ce résultat indique que la supériorité prédictive de l'EGARCH n'est pas statistiquement détectable sur la base des erreurs quadratiques.
Bien que le test de Diebold-Mariano ($p = 0.625$) ne distingue pas statistiquement les deux modèles à cause du bruit des données journalières, la corrélation élevée (0.731) entre la prévision EGARCH et la volatilité réalisée sur 10 jours valide sa performance.
La convergence des critères d'information en faveur de l'EGARCH, combinée à la non-significativité du test DM interprétée comme une limite inhérente aux données journalières plutôt que comme une preuve d'équivalence des modèles conduit à retenir l'EGARCH(1,1) comme modèle de référence. Cette décision est confortée par deux éléments structurels décisifs. D'une part, le paramètre d'asymétrie γ est hautement significatif ($\gamma = 0.171$, $t = 7.35$, $p < 0.001$), démontrant que les chocs positifs et négatifs ont des impacts asymétriques sur la volatilité conditionnelle du Brent résultat cohérent avec Kang, Kang & Yoon (2009) qui documentent ce phénomène sur les marchés pétroliers.

D'autre part, le Sign Bias Test appliqué aux résidus du GARCH(1,1) rejette formellement l'hypothèse de symétrie des chocs (Joint Effect : $p < 0.001$), indiquant que le GARCH standard est structurellement mal spécifié pour capturer la dynamique de volatilité du marché pétrolier. En définitive, la supériorité de l'EGARCH ne repose pas uniquement sur une amélioration marginale des critères numériques, mais sur une justification économétrique solide : le modèle symétrique ignore une caractéristique fondamentale et statistiquement prouvée des données, ce que l'EGARCH corrige de manière significative.

Figure 6: Superposition des volatilites conditionnelles

GARCH(1,1) vs EGARCH(1,1) - Brent (2016-2026)

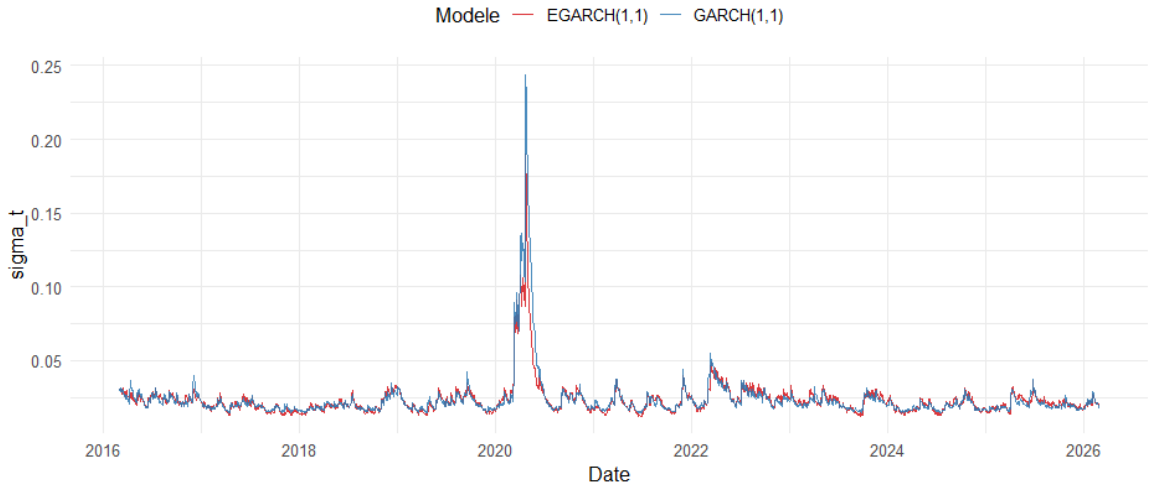

La Figure 6 présente la superposition des volatilités conditionnelles estimées par le GARCH(1,1) et l'EGARCH(1,1) sur la période 2016–2026. Les deux modèles produisent des trajectoires globalement similaires, résultat cohérent avec le test de Diebold-Mariano non significatif ($p = 0.625$). Deux épisodes de turbulence dominent la série : le choc COVID d'avril 2020, où la volatilité atteint 0.245 (soit 8 fois le niveau moyen) et la guerre en Ukraine de février 2022, avec un pic à 0.06. Des divergences locales entre les deux courbes apparaissent lors des chocs haussiers, reflétant l'effet du paramètre $\gamma > 0$ de l'EGARCH : les hausses brutales de prix génèrent une réponse de volatilité plus forte que les baisses de même amplitude, conformément à Kang, Kang & Yoon (2009).

L'évaluation out-of-sample repose sur une procédure “d'expanding window” : le modèle eGARCH(1,1)-ARMA(0,0)-Student-t est ré-estimé à chaque pas de temps sur une fenêtre croissante, débutant avec 2285 observations (mars 2016 – février 2025) et s'élargissant d'un jour à chaque itération. À chaque étape, une prévision à un horizon $h = 1$ jour est générée, produisant une séquence de 253 prévisions couvrant la période mars 2025 – mars 2026. L'horizon $h = 1$ est retenu conformément aux recommandations de la littérature : les prévisions multi-pas accumulent les erreurs et ne permettent pas une évaluation rigoureuse de la qualité prédictive (Andersen & Bollerslev, 1998).

Tableau 5: Métriques d'évaluation

Métrique	Valeur
MAE (σ^2 vs r^2)	0.00049660
RMSE (σ^2 vs r^2)	0.00086193
Corrélation σ / VR_10j	0.7313
Corrélation σ / |r_t|	0.0447
QLIKE corrigé	7.669766

La qualité des prévisions est évaluée via quatre métriques complémentaires, dont les résultats sont résumés dans le Tableau 5. Le MAE et le RMSE, calculés sur la variance (σ^2t vs r^2t), mesurent l'erreur absolue et quadratique moyenne conformément au cadre de Patton. La corrélation entre σt prévu et la volatilité réalisée sur 10 jours (VR10j = √(mean(r^2)) sur fenêtre glissante de 10 jours) constitue le critère principal d'adéquation : Andersen & Bollerslev (1998) montrent que r^2t brut est un proxy structurellement trop bruité — le plafond théorique de corrélation avec r^2t brut est de 0.15 à 0.25 sur données journalières — ce qui justifie le recours à un proxy lissé. Enfin, le QLIKE (Patton, 2011) mesure l'asymétrie de la fonction de perte entre surestimation et sous-estimation de la variance.La corrélation entre la volatilité prévue et la volatilité réalisée sur 10 jours atteint 0.731, indiquant que le modèle capture correctement les régimes de volatilité sur la période test. Ce résultat se situe dans la fourchette haute des performances typiques des modèles GARCH sur données journalières de matières premières énergétiques (Kang, Kang & Yoon, 2009). La corrélation avec le proxy brut |rt| est bien plus faible (0.045).

Le QLIKE corrigé de 7.670 calculé après exclusion des r^2t inférieurs au 5ème percentile afin d'éviter les instabilités numériques liées aux divisions par des valeurs proches de zéro indique une légère tendance à la surestimation de la variance. Cette surestimation est économiquement interprétable : le modèle est estimé sur une période incluant deux chocs majeurs (COVID 2020, Ukraine 2022), ce qui conduit à une variance inconditionnelle estimée plus élevée que celle effectivement réalisée sur la période test 2025–2026.

La Figure 7 montre que σt prévu (rouge) suit globalement la volatilité réalisée sur 10 jours (gris), avec une réactivité adéquate aux pics de juin 2025 et janvier 2026. La surestimation visible en début de période reflète le mismatch de régime entre la fenêtre d'estimation et la période test.

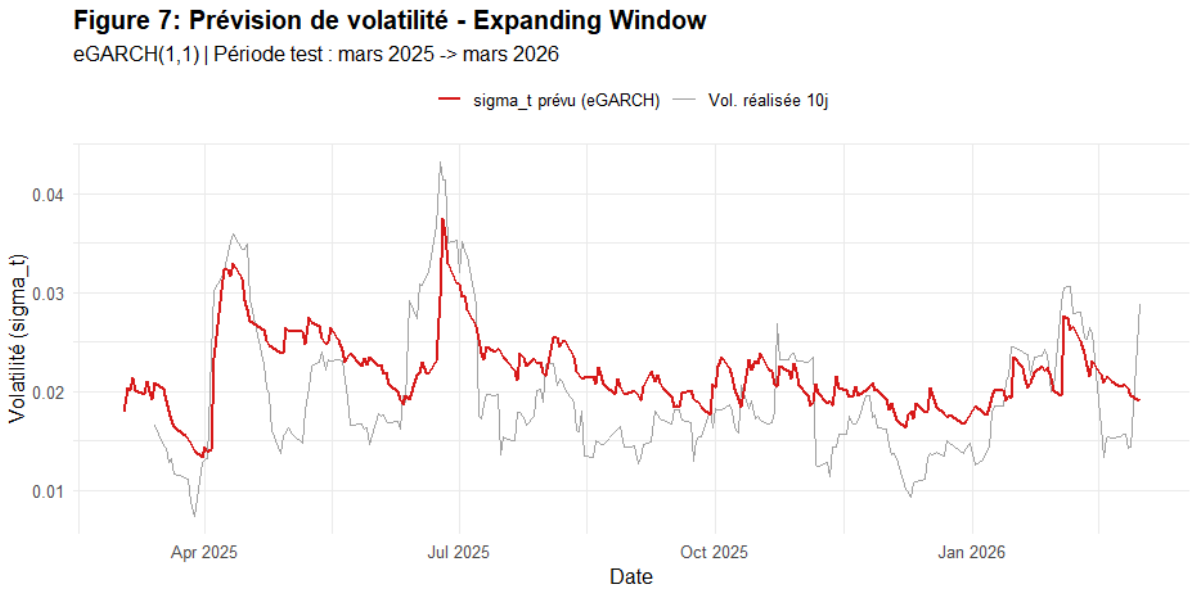

La Figure 8 confirme que les erreurs oscillent autour de zéro sur la majorité de la période (tendance loss ≈ 0), avec une légère surestimation en début et une sous-estimation en fin de période cohérente avec la montée de volatilité observée début 2026.

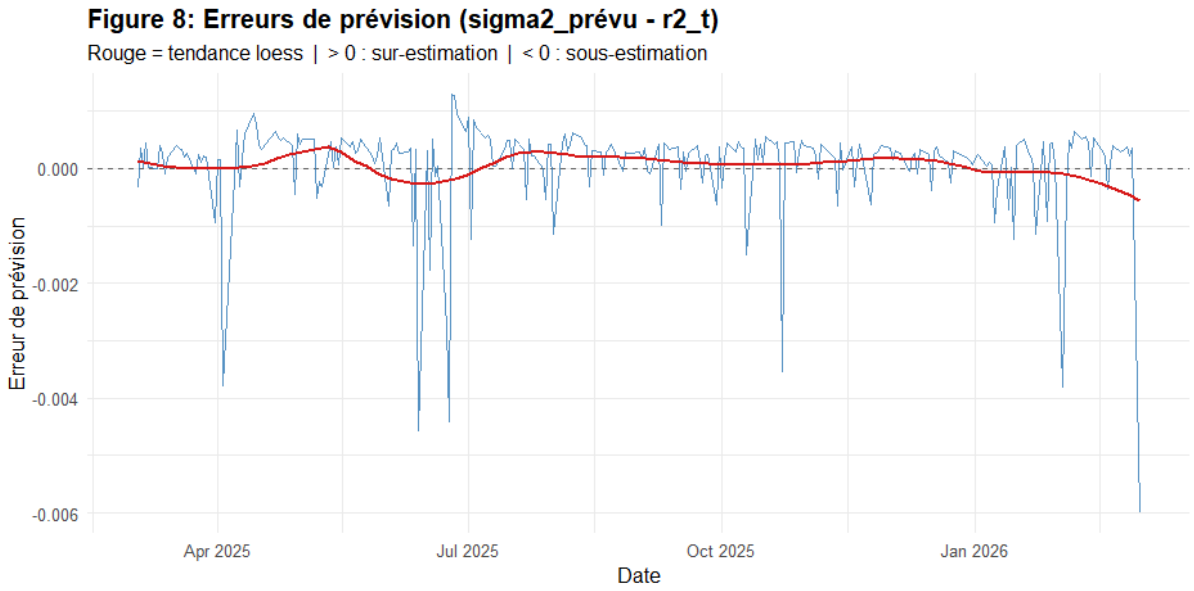

La Figure 9 illustre la relation linéaire positive entre σt prévu et VR10j (corrélation = 0.731). La droite de régression (rouge) est légèrement en dessous de la diagonale de prévision parfaite (pointillé).

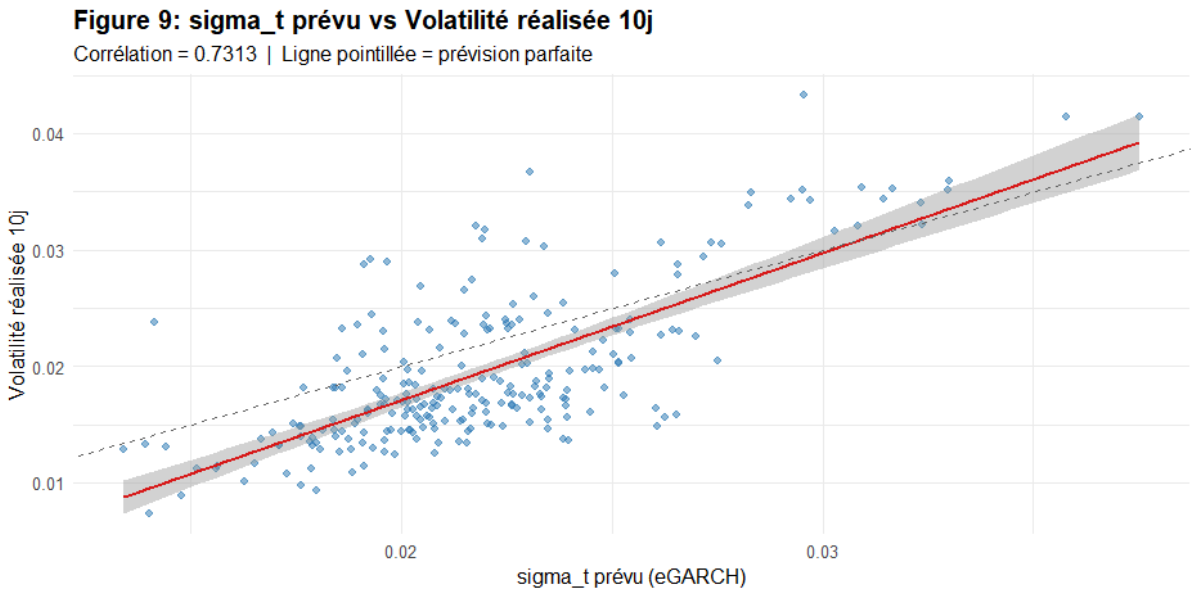

VI. Conclusion

Au terme de cette étude, nous avons analysé la dynamique de la volatilité du pétrole Brent sur une décennie marquée par des ruptures structurelles majeures. L'objectif était de déterminer si la complexité mathématique des modèles asymétriques offrait une réelle valeur ajoutée pour la gestion du risque pétrolier. L'application systématique des tests de spécification a permis de rejeter les modèles linéaires classiques. L'analyse des résidus a révélé une hétéroscédasticité conditionnelle et une leptokurticité extrême, rendant l'hypothèse de normalité obsolète. Bien que le modèle GARCH(1,1) capte efficacement la persistance de la volatilité (avec une demi-vie de 15,5 jours), il échoue à traiter l'asymétrie de l'information.

Le modèle EGARCH(1,1) avec une distribution de Student-t s'est imposé comme le modèle de référence. Il domine le GARCH symétrique sur tous les critères d'information (AIC et BIC) et parvient à réduire l'excès de kurtosis de manière significative. De plus, la significativité statistique du paramètre d'asymétrie gamma (0,171) confirme que la structure de la variance du Brent est intrinsèquement liée à la direction des chocs de prix.

L'effet de levier est une composante indispensable pour modéliser le marché du Brent. Contrairement aux modèles symétriques qui traitent une hausse ou une baisse de 10% de la même manière, l'EGARCH révèle que les chocs positifs sur les prix (souvent liés à des ruptures d'offre ou des tensions géopolitiques) génèrent une incertitude plus persistante. Si le test de Diebold-Mariano n'a pas permis de conclure à une supériorité prédictive statistique nette en raison du "bruit" des données journalières, la cohérence théorique et l'ajustement aux données (In-sample) désignent sans ambiguïté l'EGARCH comme l'outil le plus robuste pour les opérateurs de marché.

Malgré ses performances, notre approche rencontre certaines limites. La persistance d'une non-normalité résiduelle suggère que même une loi de Student peine à absorber totalement les chocs extrêmes comme celui d'avril 2020.

Pour prolonger ce travail, plusieurs pistes peuvent être explorées comme par exemple le Modèles GARCH-X, l'intégration de variables exogènes (indice de stress financier VIX, parité Dollar/Euro) permettrait de voir si la volatilité du Brent est importée d'autres segments financiers. Les ruptures structurelles, l'utilisation de modèles à changement de régime

(Markov-Switching GARCH) pourraient mieux segmenter les périodes de crise (COVID, Ukraine) des périodes de "calme" relatif, là où un modèle unique tend à surestimer la variance inconditionnelle.Les données haute fréquence, l'utilisation de l'Intraday permettrait de calculer une "Variance Réalisée" moins bruitée, offrant ainsi un test de Diebold-Mariano plus puissant.
En conclusion, la volatilité du pétrole n'est pas qu'un simple bruit statistique ; c'est une structure complexe, asymétrique et persistante. La maîtrise de ces outils de la famille GARCH reste le meilleur rempart contre l'incertitude d'un marché énergétique de plus en plus imprévisible.

VII. Bibliographie

Cours d'économétrie du M2 FMGR .

Akaike, H. (1974). *A new look at the statistical model identification. IEEE Transactions on Automatic Control.*

Andersen, T. G., & Bollerslev, T. (1998). *Answering the skeptics: Yes, standard volatility models do provide accurate forecasts. International Economic Review.*

Black, F. *(1976). Studies of stock price volatility changes. Proceedings of the 1976 Meetings of the American Statistical Association, Business and Economical Statistics Section, 177-181.*

Black, F., & Scholes, M. (1973). *The pricing of options and corporate liabilities. Journal of Political Economy, 81(3), 637-654.*

Bollerslev, T. (1986). *Generalized autoregressive conditional heteroskedasticity. Journal of Econometrics, 31(3), 307-327.*

Bollerslev, T. (1987). *A Conditionally Heteroskedastic Time Series Model for Speculative Prices and Rates of Return. The Review of Economics and Statistics, 69(3), 542-547.*

Campbell, J. Y., Lo, A. W., & MacKinlay, A. C. (1997). *The Econometrics of Financial Markets. Princeton University Press.*

Cont, R. (2001). *Empirical properties of asset returns: stylized facts and statistical issues. Quantitative Finance, 1(2), 223-236.*

Dickey, D. A., & Fuller, W. A. (1979). *Distribution of the estimators for autoregressive time series with a unit root. Journal of the American Statistical Association, 74(366a), 427-431.*

Dickey, D. A., & Fuller, W. A. (1981). *Likelihood ratio statistics for autoregressive time series with a unit root. Econometrica, 49(4), 1057-1072.*

Diebold, F. X., & Mariano, R. S. (1995). *Comparing predictive accuracy. Journal of Business & Economic Statistics (JBES).*

Engle, R. F. (1982). *Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation. Econometrica, 50(4), 987-1007.*

Engle, R. F., & Ng, V. K. *(1993). Measuring and testing the impact of news on volatility. The Journal of Finance, 48(5), 1749-1778.*

Fama, E. F. (1965). *The behavior of stock-market prices. The Journal of Business, 38(1), 34-105.*

Fama, E. F. (1970). *Efficient capital markets: A review of theory and empirical work. The Journal of Finance, 25(2), 383-417.*

Granger, C. W., & Newbold, P. (1974). *Spurious regressions in econometrics. Journal of Econometrics, 2(2), 111-120.*

Hudson, R. S., & Gregoriou, A. (2015). *Calculating and comparing security returns is harder than you think: A comparison between logarithmic and simple returns. International Review of Financial Analysis, 38, 151-162.*

Jarque, C. M., & Bera, A. K. (1980). *Efficient tests for normality, homoscedasticity and serial independence of regression residuals. Economics Letters, 6(3), 255-259.*

Kang, S. H., Kang, S. M., & Yoon, S. M. (2009). *Forecasting volatility of crude oil markets. Energy Economics.*

Kwiatkowski, D., Phillips, P. C., Schmidt, P., & Shin, Y. (1992). *Testing the null hypothesis of stationarity against the alternative of a unit root. Journal of Econometrics, 54(1-3), 159-178.*

Ljung, G. M., & Box, G. E. P. (1978). *On a measure of lack of fit in time series models. Biometrika, 65(2), 297-303.*

Maddala, G. S., & Kim, I. M. (1998). *Unit roots, cointegration, and structural change. Cambridge University Press.*

Mandelbrot, B. (1963). *The variation of certain speculative prices. The Journal of Business, 36(4), 394-419.*

Nelson, C. R., & Plosser, C. I. (1982). *Trends and random walks in macroeconomic time series: some evidence and implications. Journal of Monetary Economics, 10(2), 139-162.*

Nelson, D. B. *(1991). Conditional heteroskedasticity in asset returns: A new approach. Econometrica, 59(2), 347-370.*

Patton, A. J. (2011). *Volatility forecast comparison using imperfect volatility proxies. Journal of Econometrics.*

Samuelson, P. A. (1965). *Proof that properly anticipated prices fluctuate randomly. Industrial Management Review, 6(2), 41-49.*

Schwarz, G. (1978). *Estimating the dimension of a model. The Annals of Statistics.*

VIII. Annexes

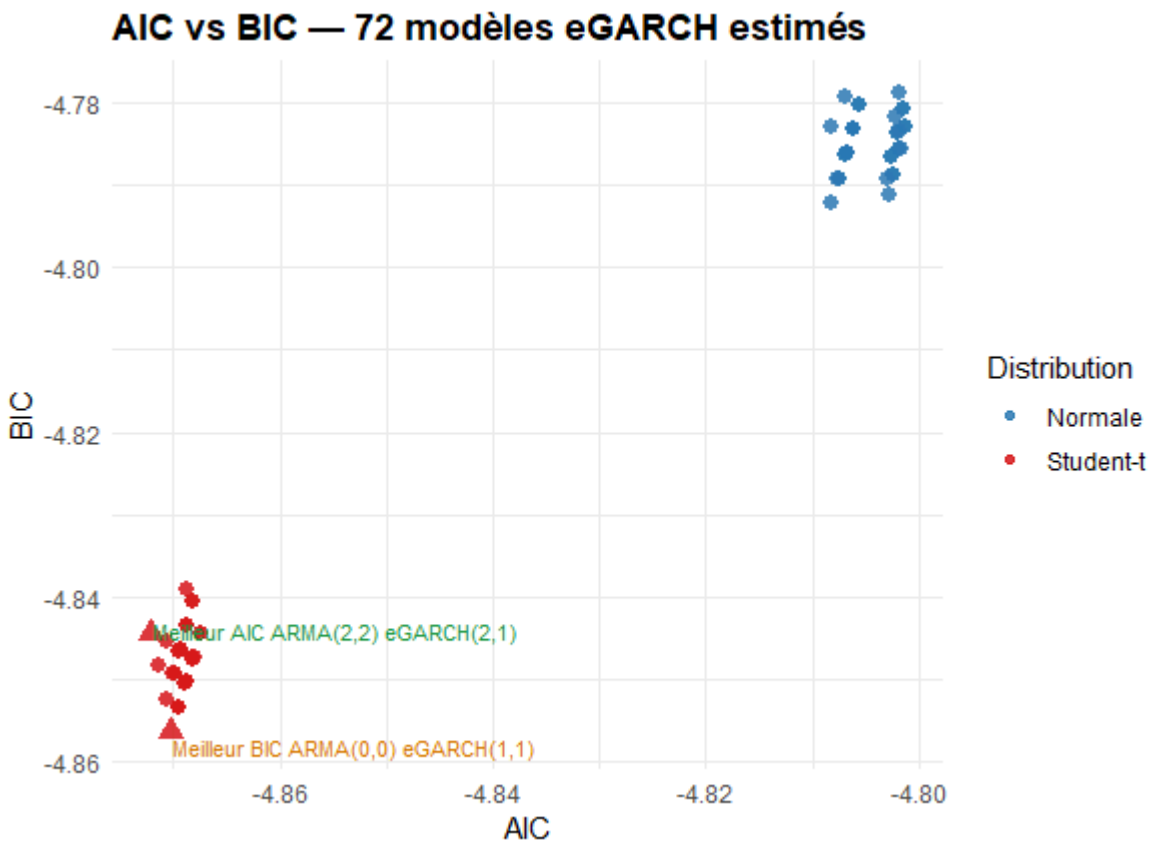

Validation choix ARMA(0,0) et student:

Afin de valider le choix de la spécification retenue, une grille de 72 modèles eGARCH a été estimée en faisant varier les ordres ARMA (p,q ∈ {0,1,2}), les ordres GARCH ({(1,1),(1,2),(2,1),(2,2)}) et la distribution des innovations (normale vs Student-t). La Figure X présente le scatter AIC vs BIC de l'ensemble des modèles estimés.
Les modèles à distribution de Student-t (rouge) dominent unanimement les modèles à distribution normale (bleu) : les 36 spécifications Student occupent l'intégralité du quadrant inférieur gauche du graphique tandis que les 36 spécifications normales se concentrent dans le quadrant supérieur droit. Cette séparation nette confirme que la distribution de Student constitue une hypothèse distributionnelle significativement supérieure pour modéliser les innovations du Brent, indépendamment de la spécification ARMA ou GARCH retenue.
Concernant le choix de la spécification ARMA, le meilleur AIC est obtenu par le modèle ARMA(2,2)-eGARCH(2,1) (AIC = −4.872) tandis que le meilleur BIC est obtenu par

l'ARMA(0,0)-eGARCH(1,1) (BIC = −4.856). Conformément au principe de parcimonie, nous privilégions le critère BIC qui pénalise plus sévèrement la complexité (Schwarz, 1978) : la spécification ARMA(0,0) est retenue, indiquant que l'ajout de moyenne mobile n'apporte pas d'amélioration suffisante pour justifier les paramètres additionnels. Ce résultat valide a posteriori le choix de modéliser la dynamique de la variance sans structure dans la moyenne.

Codes R (deux script) :

```
library(tidyverse)
library(lubridate)
library(xts)
library(zoo)
library(rugarch)
library(moments)
library(gridExtra)
library(tseries)
library(FinTS)
library(forecast)
library(patchwork)
library(flextable)


#
==========================================================================
=====
# 1. CHARGEMENT ET NETTOYAGE DES DONNÉES
#
==========================================================================
=====

brent_raw <- read_csv(
  "DCOILBRENTEU.csv",
  col_types = cols(
    DATE         = col_character(),
    DCOILBRENTEU = col_double()
  )
)

head(brent_raw, 5)

brent_raw <- brent_raw %>%
  rename(Date = observation_date,
         Prix = DCOILBRENTEU) %>%
  mutate(Date = ymd(Date))

brent_clean <- brent_raw %>%
  filter(!is.na(Prix)) %>%
```

```
  arrange(Date)


#
==========================================================================
=====
# 2. CALCUL DES LOG-RENDEMENTS
#
==========================================================================
=====

brent_clean <- brent_clean %>%
  mutate(
    Log_Prix  = log(Prix),
    Rendement = c(NA, diff(Log_Prix))
  ) %>%
  filter(!is.na(Rendement))

rendements_xts <- xts(brent_clean$Rendement, order.by = brent_clean$Date)
colnames(rendements_xts) <- "Rendement"

prix_xts <- xts(brent_clean$Prix, order.by = brent_clean$Date)
colnames(prix_xts) <- "Prix"


#
==========================================================================
=====
# 3. ANALYSE EXPLORATOIRE (EDA)
#
==========================================================================
=====

# ---- 3.1  Prix ----------------------------------------------
g1 <- ggplot(brent_clean, aes(x = Date, y = Prix)) +
  geom_line(colour = "#2c7bb6", linewidth = 0.6) +
  labs(title    = "Figure 1: Prix quotidiens du Brent",
       subtitle = "Source : FRED - DCOILBRENTEU",
       x = "Date", y = "Prix (USD/baril)") +
  theme_minimal(base_size = 13) +
  theme(plot.title = element_text(face = "bold"))

# ---- 3.2  Log-rendements -------------------------------------
g2 <- ggplot(brent_clean, aes(x = Date, y = Rendement)) +
  geom_line(colour = "#d7191c", linewidth = 0.4, alpha = 0.8) +
  geom_hline(yintercept = 0, linetype = "dashed", colour = "grey40") +
  labs(title = "Figure 2: Log-rendements journaliers du Brent",
       x = "Date", y = "Log-rendement") +
```

```
  theme_minimal(base_size = 13) +
  theme(plot.title = element_text(face = "bold"))

g1 + g2


# ---- 3.3  Histogramme + densité normale ----------------------
mu_r <- mean(brent_clean$Rendement)
sd_r <- sd(brent_clean$Rendement)

g3 <- ggplot(brent_clean, aes(x = Rendement)) +
  geom_histogram(aes(y = after_stat(density)),
                 bins = 80, fill = "#fdae61", colour = "white", alpha = 0.85) +
  stat_function(fun  = dnorm, args = list(mean = mu_r, sd = sd_r),
                colour = "#2c7bb6", linewidth = 1.1, linetype = "dashed") +
  labs(title    = "Figure 3: Distribution des log-rendements du Brent",
       subtitle = "Courbe bleue = densité normale théorique",
       x = "Log-rendement", y = "Densité") +
  theme_minimal(base_size = 13) +
  theme(plot.title = element_text(face = "bold"))
print(g3)

# ---- 3.3b  Zoom sur les queues (axe Y limité) ----------------
g3b <- ggplot(brent_clean, aes(x = Rendement)) +
  geom_histogram(aes(y = after_stat(density)),
                 bins = 80, fill = "#fdae61", colour = "white", alpha = 0.85) +
  stat_function(
    fun  = dnorm,
    args = list(mean = mu_r, sd = sd_r),
    colour = "#2c7bb6", linewidth = 1.1, linetype = "dashed"
  ) +
  coord_cartesian(ylim = c(0, 1)) +
  labs(title = "Figure 4: Zoom sur les queues",
       x = "Log-rendement", y = "Densité") +
  theme_minimal(base_size = 13) +
  theme(plot.title = element_text(face = "bold"))
print(g3b)

g3 + g3b


# ---- 3.4  Statistiques descriptives --------------------------
tableau_stats <- data.frame(
  Indicateur = c("Moyenne", "Variance", "Ecart-type", "Skewness", "Kurtosis"),
  Valeur = c(
    sprintf("%+.6f", mu_r),
    sprintf("%.6f",  var(brent_clean$Rendement)),
    sprintf("%.6f",  sd_r),
```

```
    sprintf("%+.4f", skewness(brent_clean$Rendement)),
    sprintf("%.4f",  kurtosis(brent_clean$Rendement))
  )
)

mon_tableau <- flextable(tableau_stats) %>% set_caption(caption = "Tableau 1 : Statistiques
descriptives") %>%
  theme_booktabs() %>%
  autofit() %>%
  align(align = "center", part = "all") %>%
  bold(part = "header")

mon_tableau


# ---- 3.5  ACF / PACF des rendements et rendements2 -----------
par(mfrow = c(2, 2), mar = c(4, 4, 3, 1), oma = c(0, 0, 3, 0))
acf(coredata(rendements_xts),
    lag.max = 30, main = "ACF des rendements", col = "#2c7bb6", lwd = 2)
pacf(coredata(rendements_xts),
     lag.max = 30, main = "PACF des rendements", col = "#d7191c", lwd = 2)
acf(coredata(rendements_xts)^2,
    lag.max = 30, main = "ACF des rendements2 (effet ARCH)", col = "#1a9641", lwd = 2)
pacf(coredata(rendements_xts)^2,
     lag.max = 30, main = "PACF des rendements2", col = "#fdae61", lwd = 2)

mtext("Figure 5 : Analyse de l'autocorrélation et des effets ARCH",
      side = 3, outer = TRUE, cex = 1, font = 2)

par(mfrow = c(1, 1))





lb_test <- Box.test(coredata(rendements_xts)^2, lag = 10, type = "Ljung-Box")
print(lb_test)


# ---- 3.6  Tests de stationnarité (ADF + KPSS) ----------------
# ADF  - H0 : racine unitaire -> rejet si p < 0.05 -> stationnaire
# KPSS - H0 : stationnaire   -> non-rejet si p > 0.05 -> stationnaire

adf_prix <- adf.test(coredata(log(prix_xts)), alternative = "stationary")
print(adf_prix)

adf_rend <- adf.test(coredata(rendements_xts), alternative = "stationary")
print(adf_rend)
```

```
kpss_rend <- suppressWarnings(kpss.test(coredata(rendements_xts)))
print(kpss_rend)


# ---- 3.7  Test ARCH-LM (Engle, 1982) -------------------------
# H0 : pas d'effet ARCH -> rejet si p < 0.05 -> GARCH justifie

arch_test <- ArchTest(coredata(rendements_xts), lags = 10)
print(arch_test)

jarque.bera.test(coredata(rendements_xts))


#
==========================================================================
=====
# 4. MODELISATION GARCH(1,1)
#
==========================================================================
=====

# ---- 4.1  Specification ---------------------------------------------
spec_garch <- ugarchspec(
  variance.model     = list(model = "sGARCH", garchOrder = c(1, 1)),
  mean.model         = list(armaOrder = c(0, 0), include.mean = TRUE),
  distribution.model = "std"
)

# ---- 4.2  Estimation ------------------------------------------------
fit_garch <- ugarchfit(spec = spec_garch, data = rendements_xts)
print(fit_garch)


# ---- 4.3  Coefficients ----------------------------------------------
coef_garch     <- coef(fit_garch)
alpha_g        <- coef_garch["alpha1"]
beta_g         <- coef_garch["beta1"]
demi_vie_garch <- log(0.5) / log(alpha_g + beta_g)

cat(sprintf("Persistance (alpha + beta) = %.4f\n", alpha_g + beta_g))
cat(sprintf("Demi-vie de la volatilite  = %.1f jours\n", demi_vie_garch))


# ---- 4.4  Volatilite conditionnelle ---------------------------------
sigma_garch <- sigma(fit_garch)

sigma_garch_df <- data.frame(
```

```
  Date   = index(sigma_garch),
  Sigma  = as.numeric(sigma_garch),
  Modele = "GARCH(1,1)"
)


# ---- 4.5  Diagnostics des residus -----------------------------------
residus_std_garch <- residuals(fit_garch, standardize = TRUE)

print(Box.test(coredata(residus_std_garch),   lag = 10, type = "Ljung-Box"))
print(Box.test(coredata(residus_std_garch)^2, lag = 10, type = "Ljung-Box"))


# ---- 4.6  Test de Jarque-Bera - residus GARCH(1,1) ------------------
# H0 : normalite des residus (skewness = 0, kurtosis = 3)

jb_garch <- jarque.bera.test(coredata(residus_std_garch))
print(jb_garch)

sk_garch <- skewness(coredata(residus_std_garch))
ku_garch <- kurtosis(coredata(residus_std_garch))
cat(sprintf("Skewness : %.4f | Kurtosis : %.4f | JB p-value : %.4e\n",
            sk_garch, ku_garch, jb_garch$p.value))


#
==========================================================================
=====
# 5. MODELISATION EGARCH(1,1)
#
==========================================================================
=====

# ---- 5.1  Specification ---------------------------------------------
spec_egarch <- ugarchspec(
  variance.model     = list(model = "eGARCH", garchOrder = c(1, 1)),
  mean.model         = list(armaOrder = c(0, 0), include.mean = TRUE),
  distribution.model = "std"
)

# ---- 5.2  Estimation ------------------------------------------------
fit_egarch <- ugarchfit(spec = spec_egarch, data = rendements_xts)
print(fit_egarch)


# ---- 5.3  Coefficients ----------------------------------------------
coef_egarch <- coef(fit_egarch)
```

```
if ("gamma1" %in% names(coef_egarch)) {
  cat(sprintf("Parametre de levier gamma = %.4f\n", coef_egarch["gamma1"]))
  if (coef_egarch["gamma1"] < 0) {
    cat("-> gamma < 0 : les chocs negatifs augmentent davantage la volatilite.\n")
  } else {
    cat("-> gamma > 0 : les chocs positifs augmentent davantage la volatilite.\n")
  }
}

beta_e          <- coef_egarch["beta1"]
demi_vie_egarch <- log(0.5) / log(abs(beta_e))
cat(sprintf("Persistance beta = %.4f | Demi-vie = %.1f jours\n", beta_e, demi_vie_egarch))


# ---- 5.4  Volatilite conditionnelle EGARCH ---------------------------
sigma_egarch <- sigma(fit_egarch)

sigma_egarch_df <- data.frame(
  Date   = index(sigma_egarch),
  Sigma  = as.numeric(sigma_egarch),
  Modele = "EGARCH(1,1)"
)


# ---- 5.5  Diagnostics EGARCH ----------------------------------------
residus_std_egarch <- residuals(fit_egarch, standardize = TRUE)


print(Box.test(coredata(residus_std_egarch),   lag = 10, type = "Ljung-Box"))
print(Box.test(coredata(residus_std_egarch)^2, lag = 10, type = "Ljung-Box"))


# ---- 5.6  Test de Jarque-Bera - residus EGARCH(1,1) -----------------
jb_egarch <- jarque.bera.test(coredata(residus_std_egarch))
print(jb_egarch)

sk_egarch <- skewness(coredata(residus_std_egarch))
ku_egarch <- kurtosis(coredata(residus_std_egarch))

cat(sprintf("GARCH  : skewness = %.4f | kurtosis = %.4f | JB p = %.4e\n",
            sk_garch, ku_garch, jb_garch$p.value))
cat(sprintf("EGARCH : skewness = %.4f | kurtosis = %.4f | JB p = %.4e\n",
            sk_egarch, ku_egarch, jb_egarch$p.value))


#
=====================================================================
=====
```

```
# 6. COMPARAISON GARCH vs EGARCH
#
==========================================================================
=====

# ---- 6.1  Criteres d'information -----------------------------------
aic_garch  <- infocriteria(fit_garch)[1]
bic_garch  <- infocriteria(fit_garch)[2]
aic_egarch <- infocriteria(fit_egarch)[1]
bic_egarch <- infocriteria(fit_egarch)[2]

cat(sprintf("              GARCH(1,1)   EGARCH(1,1)\n"))
cat(sprintf("AIC         : %+9.4f   %+9.4f\n", aic_garch,  aic_egarch))
cat(sprintf("BIC         : %+9.4f   %+9.4f\n", bic_garch,  bic_egarch))
cat(sprintf("Log-Lik     : %+9.2f   %+9.2f\n",
          likelihood(fit_garch), likelihood(fit_egarch)))


# ---- 6.2  Graphique comparatif -------------------------------------
sigma_compare <- rbind(sigma_garch_df, sigma_egarch_df)

g6 <- ggplot(sigma_compare, aes(x = Date, y = Sigma, colour = Modele)) +
  geom_line(linewidth = 0.45, alpha = 0.85) +
      scale_colour_manual(values   =   c("GARCH(1,1)"   =   "#2c7bb6",   "EGARCH(1,1)"   =
"#d7191c")) +
  labs(title    = "Figure 6: Superposition des volatilites conditionnelles",
      subtitle = "GARCH(1,1) vs EGARCH(1,1) - Brent (2016-2026)",
      x = "Date", y = "sigma_t", colour = "Modele") +
  theme_minimal(base_size = 13) +
  theme(plot.title = element_text(face = "bold"), legend.position = "top")
print(g6)


# ---- 6.3  Graphiques cote-a-cote -----------------------------------
p_garch  <- ggplot(sigma_garch_df,  aes(x = Date, y = Sigma)) +
  geom_line(colour = "#2c7bb6", linewidth = 0.5) +
  labs(title = "GARCH(1,1)", x = NULL, y = "sigma_t") +
  theme_minimal(base_size = 11)

p_egarch <- ggplot(sigma_egarch_df, aes(x = Date, y = Sigma)) +
  geom_line(colour = "#d7191c", linewidth = 0.5) +
  labs(title = "EGARCH(1,1)", x = NULL, y = "sigma_t") +
  theme_minimal(base_size = 11)

gridx <- grid.arrange(p_garch, p_egarch, ncol = 1,
                      top = "Volatilite conditionnelle : comparaison")
```

```
# ---- 6.4  Test de Diebold-Mariano -----------------------------------
# H0 : pouvoir predictif identique entre GARCH et EGARCH
# Erreur : e_t = r2_t - sigma2_t (variance realisee vs prevue)

r2_insample <- coredata(rendements_xts)^2
e_garch_dm  <- as.numeric(r2_insample) - as.numeric(sigma_garch)^2
e_egarch_dm <- as.numeric(r2_insample) - as.numeric(sigma_egarch)^2

dm_result <- dm.test(e_garch_dm, e_egarch_dm,
                     alternative = "two.sided",
                     h = 1, power = 2)
print(dm_result)

mse_garch  <- mean(e_garch_dm^2)
mse_egarch <- mean(e_egarch_dm^2)
cat(sprintf("MSE GARCH  : %.8f\n", mse_garch))
cat(sprintf("MSE EGARCH : %.8f\n", mse_egarch))
cat(sprintf("Ratio MSE  : %.4f  (< 1 -> EGARCH meilleur)\n", mse_egarch / mse_garch))

library(tidyverse)
library(lubridate)
library(xts)
library(rugarch)
library(gridExtra)
library(flextable)

# Décommenter si session vide (rendements_xts absent) :
brent_raw <- read_csv("DCOILBRENTEU.csv") %>%
  rename(Date = observation_date, Prix = DCOILBRENTEU) %>%
  filter(!is.na(Prix)) %>%
  arrange(Date) %>%
  mutate(Log_Prix  = log(Prix),
         Rendement = c(NA, diff(Log_Prix))) %>%
  filter(!is.na(Rendement))

rendements_xts <- xts(brent_raw$Rendement, order.by = brent_raw$Date)
colnames(rendements_xts) <- "Rendement"


#
=========================================================================
=====
# 1. DÉFINITION DE LA GRILLE
#
=========================================================================
=====

arma_grid <- expand.grid(
```

```
  arma_p = 0:2,
  arma_q = 0:2
)

garch_grid <- expand.grid(
  garch_p = 1:2,
  garch_q = 1:2
)

variance_models <- c("eGARCH")
distributions   <- c("norm", "std")

total <- nrow(arma_grid) * nrow(garch_grid) * length(distributions)
cat(sprintf("TOTAL modèles à estimer : %d\n\n", total))


#
==========================================================================
=====
# 2. BOUCLE D'ESTIMATION
#
==========================================================================
=====

resultats <- data.frame(
  Modele_Variance  = character(),
  ARMA             = character(),
  GARCH_ordre      = character(),
  Distribution     = character(),
  AIC              = numeric(),
  BIC              = numeric(),
  LogLik           = numeric(),
  Convergence      = logical(),
  stringsAsFactors = FALSE
)

compteur <- 0
n_echecs <- 0

cat("Estimation en cours...\n")
cat(rep("-", 60), "\n", sep = "")

for (vm in variance_models) {
  for (gi in 1:nrow(garch_grid)) {
    gp <- garch_grid$garch_p[gi]
    gq <- garch_grid$garch_q[gi]

    for (ai in 1:nrow(arma_grid)) {
```

```
ap <- arma_grid$arma_p[ai]
aq <- arma_grid$arma_q[ai]

for (dist in distributions) {

  compteur     <- compteur + 1
  label_modele <- sprintf("%-7s | ARMA(%d,%d) + %s(%d,%d) | %-4s",
                          vm, ap, aq, vm, gp, gq, dist)

  if (compteur %% 20 == 0 || compteur == 1) {
    cat(sprintf("[%3d/%d] %s\n", compteur, total, label_modele))
  }

  spec <- tryCatch(
    ugarchspec(
      variance.model     = list(model = vm, garchOrder = c(gp, gq)),
      mean.model         = list(armaOrder = c(ap, aq), include.mean = TRUE),
      distribution.model = dist
    ),
    error = function(e) NULL
  )

  if (is.null(spec)) { n_echecs <- n_echecs + 1; next }

  fit <- tryCatch(
    ugarchfit(spec = spec, data = rendements_xts,
              solver = "hybrid", silent = TRUE),
    error   = function(e) NULL,
    warning = function(w) suppressWarnings(
      ugarchfit(spec = spec, data = rendements_xts,
                solver = "hybrid", silent = TRUE)
    )
  )

  converge <- !is.null(fit) && fit@fit$convergence == 0

  if (!converge) {
    n_echecs <- n_echecs + 1
    resultats <- rbind(resultats, data.frame(
      Modele_Variance  = vm,
      ARMA             = sprintf("(%d,%d)", ap, aq),
      GARCH_ordre      = sprintf("(%d,%d)", gp, gq),
      Distribution     = dist,
      AIC              = NA_real_,
      BIC              = NA_real_,
      LogLik           = NA_real_,
      Convergence      = FALSE,
      stringsAsFactors = FALSE
```

```
        ))
        next
      }

      ic     <- infocriteria(fit)
      aic_v  <- ic[1]
      bic_v  <- ic[2]
      loglik <- likelihood(fit)

      resultats <- rbind(resultats, data.frame(
        Modele_Variance  = vm,
        ARMA             = sprintf("(%d,%d)", ap, aq),
        GARCH_ordre      = sprintf("(%d,%d)", gp, gq),
        Distribution     = dist,
        AIC              = round(aic_v,  6),
        BIC              = round(bic_v,  6),
        LogLik           = round(loglik, 3),
        Convergence      = TRUE,
        stringsAsFactors = FALSE
      ))

    }
  }
 }
}

cat(rep("-", 60), "\n", sep = "")
cat(sprintf("Estimation terminée : %d modèles, %d échecs de convergence.\n\n",
            compteur, n_echecs))


#
==========================================================================
=====
# 3. TABLEAUX COMPARATIFS — TOP 5 AIC ET TOP 5 BIC
#
==========================================================================
=====

res_ok <- resultats %>%
  filter(Convergence == TRUE) %>%
  arrange(AIC)

cat(sprintf("Modèles convergents : %d / %d\n\n", nrow(res_ok), total))

print(
  res_ok %>% arrange(AIC) %>% head(5) %>%
    mutate(Rang = row_number()) %>%
```

```
    select(Rang, ARMA, GARCH_ordre, Distribution, AIC, BIC, LogLik),
  row.names = FALSE
)

print(
  res_ok %>% arrange(BIC) %>% head(5) %>%
    mutate(Rang = row_number()) %>%
    select(Rang, ARMA, GARCH_ordre, Distribution, AIC, BIC, LogLik),
  row.names = FALSE
)


#
==========================================================================
=====
# 4. GRAPHIQUE — SCATTER AIC vs BIC
#
==========================================================================
=====

meilleur_aic <- res_ok %>% arrange(AIC) %>% slice(1)
meilleur_bic <- res_ok %>% arrange(BIC) %>% slice(1)

label_aic <- "ARMA(2,2) eGARCH(2,1)"
label_bic <- "ARMA(0,0) eGARCH(1,1)"

res_ok_plot <- res_ok %>%
  mutate(highlight = case_when(
    AIC == meilleur_aic$AIC & BIC == meilleur_aic$BIC ~ "Meilleur AIC",
    AIC == meilleur_bic$AIC & BIC == meilleur_bic$BIC ~ "Meilleur BIC",
    TRUE ~ "Autre"
  ))

g_scatter <- ggplot(res_ok_plot,
                    aes(x = AIC, y = BIC,
                        colour = Distribution,
                        shape  = highlight,
                        size   = highlight)) +
  geom_point(alpha = 0.85) +
  scale_colour_manual(
    values = c("std"  = "#d7191c", "norm" = "#2c7bb6"),
    labels = c("std"  = "Student-t", "norm" = "Normale")
  ) +
  scale_shape_manual(
    values = c("Meilleur AIC" = 17, "Meilleur BIC" = 17, "Autre" = 16),
    guide  = "none"
  ) +
  scale_size_manual(
```

```
    values = c("Meilleur AIC" = 3.5, "Meilleur BIC" = 3.5, "Autre" = 2.5),
    guide  = "none"
  ) +
  annotate("text",
           x = meilleur_aic$AIC + 0.0002, y = meilleur_aic$BIC + 0.0005,
           label = paste0("Meilleur AIC ", label_aic),
           colour = "#1a9641", size = 3, hjust = 0) +
  annotate("text",
           x = meilleur_bic$AIC + 0.0002, y = meilleur_bic$BIC - 0.0005,
           label = paste0("Meilleur BIC ", label_bic),
           colour = "#d97b00", size = 3, hjust = 0, vjust = 1) +
  labs(title  = "AIC vs BIC - 72 modèles eGARCH estimés",
       x = "AIC", y = "BIC", colour = "Distribution") +
  theme_minimal(base_size = 12) +
  theme(plot.title = element_text(face = "bold"), legend.position = "right")

print(g_scatter)

#
==========================================================================
=======
# PRÉVISION OUT-OF-SAMPLE — EXPANDING WINDOW
# Modèle : eGARCH(1,1) - ARMA(0,0) - Student-t
# Train  : mars 2016 -> mars 2025  (~2270 observations)
# Test   : mars 2025 -> mars 2026  (~253 observations)
# Proxy  : Volatilité réalisée 10 jours (VR_10j)
#
==========================================================================
=======


#
==========================================================================
=====
# 5. COUPURE TRAIN / TEST
#
==========================================================================
=====

date_coupure <- as.Date("2025-03-01")

r_train <- rendements_xts[index(rendements_xts) <  date_coupure]
r_test  <- rendements_xts[index(rendements_xts) >= date_coupure]

cat(sprintf("Train : %s -> %s  (%d observations)\n",
            format(start(r_train)), format(end(r_train)), nrow(r_train)))
cat(sprintf("Test  : %s -> %s  (%d observations)\n",
            format(start(r_test)),  format(end(r_test)),  nrow(r_test)))
```

```
n_test <- nrow(r_test)


#
==========================================================================
=====
# 6. SPÉCIFICATION DU MODÈLE
#
==========================================================================
=====

spec_ew <- ugarchspec(
  variance.model     = list(model = "eGARCH", garchOrder = c(1, 1)),
  mean.model         = list(armaOrder = c(0, 0), include.mean = TRUE),
  distribution.model = "std"
)


#
==========================================================================
=====
# 7. BOUCLE EXPANDING WINDOW
#
==========================================================================
=====

cat(sprintf("Expanding window - %d itérations...\n\n", n_test))

sigma_oos <- rep(NA_real_, n_test)
dates_oos <- index(r_test)
r_full    <- rendements_xts

idx_fin_train <- which(index(r_full) < date_coupure)
n_train_init  <- length(idx_fin_train)

t_start <- proc.time()

for (t in 1:n_test) {

  n_fenetre <- n_train_init + (t - 1)
  r_fenetre <- r_full[1:n_fenetre]

  fit_t <- tryCatch(
    ugarchfit(spec = spec_ew, data = r_fenetre,
              solver = "hybrid", silent = TRUE),
    error   = function(e) NULL,
    warning = function(w) suppressWarnings(
```

```
      ugarchfit(spec = spec_ew, data = r_fenetre,
                solver = "hybrid", silent = TRUE)
    )
  )

  if (!is.null(fit_t) && fit_t@fit$convergence == 0) {
    fc          <- ugarchforecast(fit_t, n.ahead = 1)
    sigma_oos[t] <- as.numeric(sigma(fc))
  }

  if (t %% 25 == 0 || t == 1 || t == n_test) {
    elapsed <- (proc.time() - t_start)["elapsed"]
    pct     <- t / n_test * 100
    restant <- if (t > 1) (elapsed / t) * (n_test - t) else NA
    cat(sprintf("  [%3d/%d]  %.0f%%  |  ecoule : %ds  |  restant : %ds\n",
                t, n_test, pct, round(elapsed),
                ifelse(is.na(restant), 0, round(restant))))
  }
}

elapsed_total <- (proc.time() - t_start)["elapsed"]
cat(sprintf("\nBoucle terminée en %.1f secondes.\n\n", elapsed_total))

n_na <- sum(is.na(sigma_oos))
if (n_na > 0) {
  cat(sprintf("%d prévision(s) NA -> interpolation linéaire.\n\n", n_na))
  sigma_oos <- zoo::na.approx(sigma_oos, na.rm = FALSE)
}


#
==========================================================================
=====
# 8. PROXY DE VOLATILITÉ RÉALISÉE — VR_10j
#
==========================================================================
=====

r_test_vec <- as.numeric(r_test)
r2_test    <- r_test_vec^2
absr_test  <- abs(r_test_vec)

# VR_10j = sqrt(mean(r²)) sur 10 jours glissants — même unité que sigma_t
vol_realisee_10j <- zoo::rollapply(
  r2_test, width = 10,
  FUN  = function(x) sqrt(mean(x)),
  fill = NA, align = "right"
)
```

```
df_oos <- data.frame(
  Date        = dates_oos,
  Sigma_prevu = sigma_oos,
  r2          = r2_test,
  AbsR        = absr_test,
  VR_10j      = vol_realisee_10j
)


#
=========================================================================
=====
# 9. MÉTRIQUES D'ÉVALUATION
#
=========================================================================
=====

sigma2_oos <- sigma_oos^2

idx_valide <- !is.na(sigma2_oos) & !is.na(r2_test)
mae_var    <- mean(abs(sigma2_oos[idx_valide] - r2_test[idx_valide]))
rmse_var   <- sqrt(mean((sigma2_oos[idx_valide] - r2_test[idx_valide])^2))

idx_10j  <- !is.na(sigma_oos) & !is.na(vol_realisee_10j)
cor_10j  <- cor(sigma_oos[idx_10j], vol_realisee_10j[idx_10j])
cor_brut <- cor(sigma_oos[idx_valide], absr_test[idx_valide])

# QLIKE — filtre r² < 5e percentile pour éviter divisions par ~0
seuil_qlike <- quantile(r2_test[r2_test > 0], probs = 0.05)
idx_qlike   <- idx_valide & r2_test > seuil_qlike
qlike <- mean(
  sigma2_oos[idx_qlike] / r2_test[idx_qlike] -
    log(sigma2_oos[idx_qlike] / r2_test[idx_qlike]) - 1
)

cat(sprintf("MAE   (sigma2 vs r2)       : %.8f\n", mae_var))
cat(sprintf("RMSE  (sigma2 vs r2)       : %.8f\n", rmse_var))
cat(sprintf("Corrélation sigma / VR_10j : %.4f\n", cor_10j))
cat(sprintf("Corrélation sigma / |r_t|  : %.4f\n", cor_brut))
cat(sprintf("QLIKE corrigé              : %.6f\n", qlike))


#
=========================================================================
=====
# 10. GRAPHIQUES
```

```
#
==========================================================================
=====

# ---- 10.1  sigma_t prévu vs VR_10j ----------------------------------------
g_fw1 <- ggplot(df_oos, aes(x = Date)) +
  geom_line(aes(y = VR_10j,      colour = "Vol. réalisée 10j"),
            linewidth = 0.6, alpha = 0.9) +
  geom_line(aes(y = Sigma_prevu, colour = "sigma_t prévu (eGARCH)"),
            linewidth = 0.8) +
  scale_colour_manual(values = c(
    "Vol. réalisée 10j"      = "#999999",
    "sigma_t prévu (eGARCH)" = "#d7191c"
  )) +
  labs(title    = "Figure 7: Prévision de volatilité - Expanding Window",
       subtitle = "eGARCH(1,1) | Période test : mars 2025 -> mars 2026",
       x = "Date", y = "Volatilité (sigma_t)", colour = NULL) +
  theme_minimal(base_size = 13) +
  theme(plot.title = element_text(face = "bold"), legend.position = "top")
print(g_fw1)

# ---- 10.2  Erreurs de prévision dans le temps -------------------------------
df_oos <- df_oos %>%
  mutate(Erreur = Sigma_prevu^2 - r2)

g_fw2 <- ggplot(df_oos, aes(x = Date, y = Erreur)) +
  geom_hline(yintercept = 0, linetype = "dashed", colour = "grey40") +
  geom_line(colour = "#2c7bb6", linewidth = 0.5, alpha = 0.8) +
  geom_smooth(method = "loess", span = 0.3,
              colour = "#d7191c", se = FALSE, linewidth = 1) +
  labs(title    = "Figure 8: Erreurs de prévision (sigma2_prévu - r2_t)",
       subtitle = "Rouge = tendance loess  |  > 0 : sur-estimation  |  < 0 : sous-estimation",
       x = "Date", y = "Erreur de prévision") +
  theme_minimal(base_size = 13) +
  theme(plot.title = element_text(face = "bold"))
print(g_fw2)

# ---- 10.3  Scatter sigma_t prévu vs VR_10j ----------------------------------
g_fw3 <- ggplot(df_oos %>% filter(!is.na(VR_10j)),
                aes(x = Sigma_prevu, y = VR_10j)) +
  geom_point(alpha = 0.5, size = 1.8, colour = "#2c7bb6") +
  geom_smooth(method = "lm", colour = "#d7191c", se = TRUE, linewidth = 1) +
  geom_abline(slope = 1, intercept = 0,
              linetype = "dashed", colour = "grey40") +
  labs(title    = "Figure 9: sigma_t prévu vs Volatilité réalisée 10j",
       subtitle = sprintf("Corrélation = %.4f  |  Ligne pointillée = prévision parfaite",
                          cor_10j),
       x = "sigma_t prévu (eGARCH)", y = "Volatilité réalisée 10j") +
```

```
  theme_minimal(base_size = 13) +
  theme(plot.title = element_text(face = "bold"))
print(g_fw3)

# ---- 10.4  Vue complète train + test ----------------------------------------
fit_full_train <- ugarchfit(spec = spec_ew, data = r_train,
                            solver = "hybrid", silent = TRUE)

sigma_full_df <- rbind(
  data.frame(Date    = as.Date(index(r_train)),
             Sigma   = as.numeric(sigma(fit_full_train)),
             Periode = "In-sample (train)"),
  data.frame(Date    = as.Date(dates_oos),
             Sigma   = sigma_oos,
             Periode = "Out-of-sample (test)")
)

g_fw4 <- ggplot(sigma_full_df, aes(x = Date, y = Sigma, colour = Periode)) +
  geom_line(linewidth = 0.5) +
  geom_vline(xintercept = date_coupure,
             linetype = "dashed", colour = "black", linewidth = 0.8) +
  annotate("text",
           x     = date_coupure,
           y     = max(sigma_full_df$Sigma, na.rm = TRUE) * 0.95,
           label = "  Coupure\n  mars 2025",
           hjust = 0, size = 3.5, colour = "black") +
  scale_colour_manual(values = c(
    "In-sample (train)"    = "#2c7bb6",
    "Out-of-sample (test)" = "#d7191c"
  )) +
  labs(title    = "Volatilité conditionnelle - Vue complète (2016-2026)",
       subtitle = "Bleu = in-sample  |  Rouge = out-of-sample (expanding window)",
       x = "Date", y = "sigma_t", colour = NULL) +
  theme_minimal(base_size = 13) +
  theme(plot.title = element_text(face = "bold"), legend.position = "top")
print(g_fw4)
```